


Método de evaluación para modelo integrante de un sistema clasificador (Análisis de peor caso)

Introducción


Para resolver un problema de clasificación, se tiene un sistema compuesto con distintos modelos componentes en paralelo y un fusionador. Cada uno de esos modelos mira features de los datos y devuelve una clase. Luego se fusionan sus resultados mediante algún método, resultando en que el sistema determina la clase del dato de forma unívoca.

Particularmente, el sistema resuelve problemas de clasificación binaria.

Sistema Clasificador




Sistema ejemplo



Objetivo

- ▶ Evaluar un modelo componente de forma independiente al sistema
- ▶ Obtener una estimación del rendimiento del sistema o una función de costo del sistema en base a esa evaluación

Objetivo



Información disponible

Datos de los que se dispone para el problema:

- ▶ El sistema compuesto incompleto, faltando un modelo
- ▶ Una función de costo para el sistema
- ▶ Datos para la evaluación del sistema
- ▶ El modelo componente a evaluar
- ▶ Datos para la evaluación del modelo

Información disponible

- ▶ Ambos conjuntos de datos pueden o no ser el mismo.
- ▶ La función de costo del modelo es la que se busca proponer.

Motivación

Una posible utilidad de esta función de costo puede ser realizar búsqueda de hiperparámetros.

Se puede querer reemplazar o añadir un modelo al sistema. Al momento de realizar la búsqueda de hiperparámetros para ese nuevo modelo, con esta función de costo se puede comparar entre modelos de forma mucho mas rápida y así elegir a los más adecuados, al no tener que ejecutar el sistema para cada modelo.

Intervención

Se va a utilizar una operación sobre el sistema llamada intervención, basada en la intervención de las redes bayesianas.


Al sistema incompleto, en el lugar del modelo se le inserta una función de clasificación constante. Esta función ignora el dato de entrada y devuelve siempre el mismo resultado de clasificación.

Intervención

Los dos casos de intervención que serán usados son la evaluación del sistema con un componente que devuelve siempre Positive y con uno que devuelve siempre Negative.

Luego se podría calcular la matriz de confusión asociada a sus resultados.

Intervención ejemplo



Costo en peor caso

Para poder comparar entre modelos se separa el proceso en dos partes:

- ▶ Primero es evaluado el sistema sin el modelo, usando la intervención. Se registran las probabilidades de acierto en el sistema intervenido con un modelo que da siempre positive, y uno que da siempre negative.
- ▶ Luego usando esos valores, se ejecuta el modelo de forma independiente para calcular alguna función de costo asociada.

Costo en peor caso

- ▶ La métrica a evaluar va a ser, dado un sistema y dada la matriz de confusión de un modelo, calcular una cota al costo del sistema, es decir, el peor caso del sistema dado que tenga al modelo como componente.

Problema 1: Mismo dataset

El primer problema a resolver entonces va a ser encontrar una función de costo para el modelo con las siguientes condiciones:

- ▶ La función devuelve el peor caso del sistema dado que fuera ejecutado con el modelo
- ▶ Se tiene el resultado de ejecutar el sistema con intervención Positive y Negative en el modelo
- ▶ Los datasets para evaluar el modelo y el sistema son el mismo

Funciones de costo

	Pos	Neg
Pos	7	3
Neg	4	6

Table: Confusión del modelo



	Pos	Neg
Pos	?	?
Neg	?	?

Table: Confusión del sistema

Funciones de costo

	Pos	Neg
Pos	5	5
Neg	4	6

Table: Confusión del modelo

	Pos	Neg
Pos	7	3
Neg	6	4

Table: Intervención positive

	Pos	Neg
Pos	2	8
Neg	1	9

Table: Intervención negative

	Pos	Neg
Pos	?	?
Neg	?	?

Table: Confusión del sistema

Notación

$$m_{ij}^{f,D} = |\{d \in D \mid f(d_1) = j \wedge d_2 = i\}|$$

- ▶ i es la clase real
- ▶ j es la clase que predice el modelo f
- ▶ D es el dataset utilizado, conteniendo un conjunto de pares d_1 instancia, d_2 clase real asociada, y su valor por defecto que representa todos los datos disponibles es D
- ▶ f es el modelo usado y puede valer:
 - ▶ M como el modelo a analizar
 - ▶ S_M como el sistema compuesto con el modelo M
 - ▶ $S_{* \rightarrow x}$ como el sistema intervenido, donde el componente es la función de clasificación constante que devuelve la clase x

Especificación del problema

Se asume lo siguiente sobre el comportamiento del sistema para cualquier conjunto de instancias D , modelo M y sistema S_M :

$$\begin{aligned} \blacktriangleright \{d \in D \mid d_2 = p \wedge S_M(d_1) = p\} \subseteq \\ \{d \in D \mid d_2 = p \wedge S_{* \rightarrow p}(d_1) = p\} \end{aligned}$$

\\ Agregar evidencia solo puede mejorar la predicción

Especificación del problema

Se asume lo siguiente sobre el comportamiento del sistema para cualquier conjunto de instancias D , modelo M y sistema S_M :

$$\blacktriangleright \{d \in D \mid d_2 = p \wedge S_M(d_1) = n\} \subseteq \{d \in D \mid d_2 = p \wedge S_{* \rightarrow n}(d_1) = n\}$$

\\ Restar evidencia solo puede empeorar la predicción

Especificación del problema

Se asume lo siguiente sobre el comportamiento del sistema para cualquier conjunto de instancias D , modelo M y sistema S_M :

- ▶ $\{d \in D \mid d_2 = p \wedge S_M(d_1) = p\} \subseteq \{d \in D \mid d_2 = p \wedge S_{* \rightarrow p}(d_1) = p\}$
- ▶ $\{d \in D \mid d_2 = p \wedge S_M(d_1) = n\} \subseteq \{d \in D \mid d_2 = p \wedge S_{* \rightarrow n}(d_1) = n\}$
- ▶ $\{d \in D \mid d_2 = n \wedge S_M(d_1) = n\} \subseteq \{d \in D \mid d_2 = n \wedge S_{* \rightarrow n}(d_1) = n\}$
- ▶ $\{d \in D \mid d_2 = n \wedge S_M(d_1) = p\} \subseteq \{d \in D \mid d_2 = n \wedge S_{* \rightarrow p}(d_1) = p\}$

\\ Lo mismo para Clase Negative

Especificación del problema

Se espera lo siguiente sobre la función de costo asociada a las confusiones del sistema:

- ▶ $Costo_{TP}^{S_M} \leq Costo_{FN}^{S_M}$

- ▶ $Costo_{TN}^{S_M} \leq Costo_{FP}^{S_M}$

Los fallos tienen mayor costo que los aciertos.

Para este trabajo se va a asumir que los aciertos tienen costo 0 y los fallos costo 1.

Especificación del problema

Datos disponibles:

	Pred Pos	Pred Neg
Clase Pos	$m_{TP}^{S^* \rightarrow p, D}$	$m_{FN}^{S^* \rightarrow p, D}$
Clase Neg	$m_{FP}^{S^* \rightarrow p, D}$	$m_{TN}^{S^* \rightarrow p, D}$

Table: Matriz de confusión del sistema si Modelo = Positive

	Pred Pos	Pred Neg
Clase Pos	$m_{TP}^{S^* \rightarrow n, D}$	$m_{FN}^{S^* \rightarrow n, D}$
Clase Neg	$m_{FP}^{S^* \rightarrow n, D}$	$m_{TN}^{S^* \rightarrow n, D}$

Table: Matriz de confusión del sistema si Modelo = Negative

Especificación del problema

Otros datos disponibles:

	Positive	Negative
#Instancias	P	N

Table: Cantidad de instancias por clase

	Pred Pos	Pred Neg
Clase Pos	$m_{TP}^{M,D}$	$m_{FN}^{M,D}$
Clase Neg	$m_{FP}^{M,D}$	$m_{TN}^{M,D}$

Table: Matriz de confusión del modelo

Especificación del problema

Dados esos datos, se busca generar la peor matriz de confusión posible del sistema que sea válida (peor caso).

	Prediccion Positive	Prediccion Negative
Clase Positive	$m_{TP}^{S_M, D}$	$m_{FN}^{S_M, D}$
Clase Negative	$m_{FP}^{S_M, D}$	$m_{TN}^{S_M, D}$

Table: Matriz de confusión del sistema

Especificación del problema

La peor es la que maximiza:

$$\begin{aligned} \blacktriangleright & m_{TP}^{S_M, D} * Costo_{TP}^{S_M} + m_{FN}^{S_M, D} * Costo_{FN}^{S_M} + \\ & m_{FP}^{S_M, D} * Costo_{FP}^{S_M} + m_{TN}^{S_M, D} * Costo_{TN}^{S_M} \end{aligned}$$

Como los costos asociados a las confusiones de aciertos valen 0 y las de los fallos 1, es equivalente a maximizar:

$$\blacktriangleright m_{FN}^{S_M, D} + m_{FP}^{S_M, D}$$

El análisis también vale para otros casos.

Planteo inicial

Para lograr esto se va a analizar de forma cercana los comportamientos posibles de las instancias.

Una instancia se puede caracterizar de 4 formas distintas:

1. Sistema acierta independientemente del modelo.
2. Sistema acierta solo si el modelo falla.
3. Sistema acierta solo si el modelo acierta.
4. Sistema falla independientemente del modelo.

Planteo inicial

El problema se va a trabajar como un problema adversarial.

Se sabe que predice el modelo para cada instancia, pero no cuál será el resultado que tendría sistema para la instancia, ya que se desconoce de que tipo es.

El objetivo del adversario va a ser para el conjunto de instancias, y en base al resultado del modelo para cada instancia, asignarle un tipo a cada una de ellas de forma que la cantidad de fallos del sistema sea máxima.

Comportamiento de instancias

La siguiente tabla tiene los posibles casos en los que se puede encontrar una instancia con respecto al resultado del sistema en ella en base al resultado del modelo.

Comportamiento de instancias

Recordando la assumption de la clase Positive:

$$\begin{aligned} \blacktriangleright \{d \in D \mid d_2 = p \wedge S_M(d_1) = p\} \subseteq \\ \{d \in D \mid d_2 = p \wedge S_{* \rightarrow p}(d_1) = p\} \end{aligned}$$

	$S_{* \rightarrow p}(i)$	$S_{* \rightarrow n}(i)$	¿Es factible?
Tipo 1	p	p	
Tipo 2	n	p	
Tipo 3	p	n	
Tipo 4	n	n	

Table: Resultados posibles en instancias de clase Positive

Comportamiento de instancias

Recordando la assumption de la clase Positive:

$$\begin{aligned} \blacktriangleright \{d \in D \mid d_2 = p \wedge S_M(d_1) = p\} \subseteq \\ \{d \in D \mid d_2 = p \wedge S_{* \rightarrow p}(d_1) = p\} \end{aligned}$$

	$S_{* \rightarrow p}(i)$	$S_{* \rightarrow n}(i)$	¿Es factible?
Tipo 1	p	p	SI
Tipo 2	n	p	
Tipo 3	p	n	
Tipo 4	n	n	

Table: Resultados posibles en instancias de clase Positive

Comportamiento de instancias

Recordando la assumption de la clase Positive:

$$\begin{aligned} \text{► } \{d \in D \mid d_2 = p \wedge S_M(d_1) = p\} &\subseteq \\ \{d \in D \mid d_2 = p \wedge S_{* \rightarrow p}(d_1) = p\} \end{aligned}$$

	$S_{* \rightarrow p}(i)$	$S_{* \rightarrow n}(i)$	¿Es factible?
Tipo 1	p	p	SI
Tipo 2	n	p	NO
Tipo 3	p	n	
Tipo 4	n	n	

Table: Resultados posibles en instancias de clase Positive

Comportamiento de instancias

Recordando la assumption de la clase Positive:

$$\begin{aligned} \blacktriangleright \{d \in D \mid d_2 = p \wedge S_M(d_1) = p\} \subseteq \\ \{d \in D \mid d_2 = p \wedge S_{* \rightarrow p}(d_1) = p\} \end{aligned}$$

	$S_{* \rightarrow p}(i)$	$S_{* \rightarrow n}(i)$	¿Es factible?
Tipo 1	p	p	SI
Tipo 2	n	p	NO
Tipo 3	p	n	SI
Tipo 4	n	n	

Table: Resultados posibles en instancias de clase Positive

Comportamiento de instancias

Recordando la assumption de la clase Positive:

$$\begin{aligned} \blacktriangleright \{d \in D \mid d_2 = p \wedge S_M(d_1) = p\} \subseteq \\ \{d \in D \mid d_2 = p \wedge S_{* \rightarrow p}(d_1) = p\} \end{aligned}$$

	$S_{* \rightarrow p}(i)$	$S_{* \rightarrow n}(i)$	¿Es factible?
Tipo 1	p	p	SI
Tipo 2	n	p	NO
Tipo 3	p	n	SI
Tipo 4	n	n	SI

Table: Resultados posibles en instancias de clase Positive

Comportamiento de instancias

Solo las instancias de tipo 3 son en las que el adversario puede decidir para afectar el resultado del sistema:

- ▶ Las instancias de tipo 1 nunca fallan independientemente del resultado del modelo
- ▶ No hay instancias de tipo 2
- ▶ Las instancias de tipo 3 solo fallan si el modelo falla
- ▶ Las instancias de tipo 4 siempre fallan independientemente del resultado del modelo

Comportamiento de instancias

A su vez, el total de instancias de la clase Positive es equivalente a la suma de instancias tipo 1, 3 y 4, ya que de tipo 2 no pueden existir para ningún sistema que cumpla con la especificación.

Estrategia

La estrategia del adversario entonces va a consistir en inflar la cantidad de instancias de tipo 3 en las que el modelo falla, para con eso provocar el fallo en el sistema.

Las instancias de tipo 1 y 4 son irrelevantes para el adversario por lo que las puede asignar tanto a aciertos, como a los fallos restantes del modelo.

Fallos en peor caso

Para la clase Positive, la fórmula que da la cantidad de fallos totales basados en esa estrategia es la siguiente:

$$\blacktriangleright \text{InstanciasTipo4} + \text{Min}(\text{FallosDelModelo}, \text{InstanciasTipo3})$$

Fallos en peor caso

Para la clase Positive, la fórmula que da la cantidad de fallos totales basados en esa estrategia es la siguiente:

- ▶ $\text{InstanciasTipo4} + \text{Min}(\text{FallosDelModelo}, \text{InstanciasTipo3})$
- ▶ Todas las instancias de tipo 4 suman un fallo

Fallos en peor caso

Para la clase Positive, la fórmula que da la cantidad de fallos totales basados en esa estrategia es la siguiente:

- ▶ $\text{InstanciasTipo4} + \text{Min}(\text{FallosDelModelo}, \text{InstanciasTipo3})$
- ▶ Todas las instancias de tipo 4 suman un fallo
- ▶ Las instancias de tipo 1 no suman fallos

Fallos en peor caso

Para la clase Positive, la fórmula que da la cantidad de fallos totales basados en esa estrategia es la siguiente:

- ▶ $\text{InstanciasTipo4} + \text{Min}(\text{FallosDelModelo}, \text{InstanciasTipo3})$
- ▶ Todas las instancias de tipo 4 suman un fallo
- ▶ Las instancias de tipo 1 no suman fallos
- ▶ El modelo falla para todas las instancias de tipo 3 que sea posible

Fallos en peor caso

Para la clase Positive, la fórmula que da la cantidad de fallos totales basados en esa estrategia es la siguiente:

- ▶ $\text{InstanciasTipo4} + \text{Min}(m_{FN}^{M,D}, \text{InstanciasTipo3})$
- ▶ La cantidad de fallos del modelo es la confusion de Falsos Negativos

Fallos en peor caso

Si se pudiera saber la cantidad de instancias de cada tipo disponibles, se tiene la solución al peor caso.

Fallos en peor caso

Instancias de tipo 1:

- ▶ Tanto la intervención Positive como Negative del sistema aciertan
- ▶ Se saben las confusiones con intervención: $m_{TP}^{S_* \rightarrow p, D}$ y $m_{TP}^{S_* \rightarrow n, D}$
- ▶ A su vez, en base a las assumptions, se sabe que las instancias que suman en $m_{TP}^{S_* \rightarrow n, D}$ también están en $m_{TP}^{S_* \rightarrow p, D}$ ya que se está agregando evidencia
- ▶ $m_{TP}^{S_* \rightarrow n, D}$ es la cantidad de instancias tipo 1

Fallos en peor caso

Instancias de tipo 4:

- ▶ Tanto la intervención Positive como Negative del sistema fallan
- ▶ Se saben las confusiones con intervención: $m_{FN}^{S_{*} \rightarrow p, D}$ y $m_{FN}^{S_{*} \rightarrow n, D}$
- ▶ A su vez, en base a las assumptions, se sabe que las instancias que suman en $m_{FN}^{S_{*} \rightarrow p, D}$ también están en $m_{FN}^{S_{*} \rightarrow n, D}$ ya que se está quitando evidencia
- ▶ $m_{FN}^{S_{*} \rightarrow p, D}$ es la cantidad de instancias tipo 4

Fallos en peor caso

Instancias de tipo 3:

- ▶ Solo la intervención Positive del sistema acierta
- ▶ Son las instancias restantes de la clase Positive

Fallos en peor caso

La cantidad de instancias de tipo 3 es:

- ▶ CantidadPositive - $m_{FN}^{S_{*} \rightarrow p, D} - m_{TP}^{S_{*} \rightarrow n, D}$
- ▶ $(m_{TP}^{S_{*} \rightarrow p, D} + m_{FN}^{S_{*} \rightarrow p, D}) - m_{FN}^{S_{*} \rightarrow p, D} - m_{TP}^{S_{*} \rightarrow n, D}$
- ▶ $m_{TP}^{S_{*} \rightarrow p, D} - m_{TP}^{S_{*} \rightarrow n, D}$

Esta resta en la cuenta representa las instancias en las que el sistema solo acierta si el modelo acierta, coincidiendo con las de tipo 3.

Fallos en peor caso

Recordando la fórmula de peor caso:

$$\blacktriangleright \text{InstanciasTipo4} + \text{Min}(m_{FN}^{M,D}, \text{InstanciasTipo3})$$

Reemplazando por las cantidades de instancias de cada tipo:

$$\blacktriangleright m_{FN}^{S_{*} \rightarrow p, D} + \text{Min}(m_{FN}^{M,D}, m_{TP}^{S_{*} \rightarrow p, D} - m_{TP}^{S_{*} \rightarrow n, D})$$

Fallos en peor caso

Se puede hacer el mismo análisis para la clase Negative, llegando a lo siguiente:

- ▶ Clase Positive: $m_{FN}^{S_{* \rightarrow p}, D} + \text{Min}(m_{FN}^{M, D}, m_{TP}^{S_{* \rightarrow p}, D} - m_{TP}^{S_{* \rightarrow n}, D})$
- ▶ Clase Negative: $m_{FP}^{S_{* \rightarrow n}, D} + \text{Min}(m_{FP}^{M, D}, m_{TN}^{S_{* \rightarrow n}, D} - m_{TN}^{S_{* \rightarrow p}, D})$

Resultando en el peor caso del sistema:

- ▶ $m_{FN}^{S_{* \rightarrow p}, D} + \text{Min}(m_{FN}^{M, D}, m_{TP}^{S_{* \rightarrow p}, D} - m_{TP}^{S_{* \rightarrow n}, D}) +$
 $m_{FP}^{S_{* \rightarrow n}, D} + \text{Min}(m_{FP}^{M, D}, m_{TN}^{S_{* \rightarrow n}, D} - m_{TN}^{S_{* \rightarrow p}, D})$

Problema 2: Distintos datasets

El segundo problema a resolver entonces va a ser analizar la función de costo para el modelo cuando los datasets sean distintos:

- ▶ La función de costo de peor caso del modelo en el sistema es la anterior
- ▶ Los datasets para evaluar el modelo y el sistema son distintos
- ▶ Los datos de ambos datasets provienen de la misma distribución

Datos faltantes

Recordando la función de costo de peor caso:

$$m_{FN}^{S_* \rightarrow p, D} + \text{Min}(m_{FN}^{M, D}, m_{TP}^{S_* \rightarrow p, D} - m_{TP}^{S_* \rightarrow n, D})$$

- ▶ Las confusiones del modelo se ejecutan con el dataset del modelo sin problemas
- ▶ Las confusiones del sistema intervenido se ejecutan con un dataset distinto
- ▶ Se van a estimar las confusiones que hubiera tenido el sistema intervenido en el dataset del modelo

Datos faltantes

Teniendo la confusión resultante de correr un sistema intervenido para un dataset, se estima la confusión en otro de forma simple:

- ▶ Primero se divide cada confusión por la cantidad de instancias de su clase para saber el accuracy
- ▶ Luego se multiplica cada accuracy por la cantidad de instancias de su clase correspondiente en el dataset del modelo


$$\overline{m_{TP}^{S_{*} \rightarrow p, D}} = m_{TP}^{S_{*} \rightarrow p, D'} * CantPositive^D / CantPositive^{D'}$$

Experimentación

Se van a realizar 2 experimentos para comprobar esto:

- ▶ Dos 2 modelos clasificadores en paralelo
- ▶ Fusionador OR/AND lógico
- ▶ Se simulan con variables aleatorias los resultados de clasificación de cada modelo

Experimentación



Metodología

Para ambos experimentos la operación es la siguiente:

- ▶ Se simula y guarda el resultado de la intervención en un dataset
- ▶ Se simula el resultado del modelo para otro dataset
- ▶ Se calcula la función de costo de peor caso estimando las confusiones de intervención
- ▶ Se ejecuta el sistema completo en el dataset del modelo para comprobar los resultados


Experimento 1

- ▶ Los accuracies de ambos modelos 0.5 ambas clases
- ▶ Fusionador de tipo OR
- ▶ Correlación clase Positive de 0.95
- ▶ Correlación clase Negative de -0.95

Se asignan distintos tamaños en cada dataset y para cada combinación se ejecuta 1000 veces y se reporta:

- ▶ $P(\text{PeorCasoEstimado} \geq \text{EvalReal})$

Experimento 1



Experimento 1

La probabilidad se acerca rápidamente a 1 a medida que ambas cantidades de instancias aumentan.

Para el caso de un sistema con dos modelos, a tamaños no tan grandes, el peor caso usando datasets distintos provee casi la misma información que con un solo dataset.


Experimento 2

- ▶ Accuracies de ambos modelos aleatorias
- ▶ Fusionador aleatorio entre OR y AND
- ▶ Correlaciones aleatorias válidas para los accuracies

Los tamaños de ambos datasets tienen 10000 instancias por clase, se ejecuta 100000 veces y se reporta:

▶
$$\frac{EvalReal}{PeorCasoEstimado}$$

Experimento 2



Experimento 2

El cociente entre ambos valores no suele pasar 1, siendo esto el resultado buscado. Incluso en los raros casos en los que si lo supera, no lo hace por un margen muy grande.

Explicación

La causa de estos resultados es que ambos datasets tienen datos provenientes de la misma distribución.

Por ley de los grandes números, a medida que aumenta la cantidad de instancias de cada dataset se puede saber lo siguiente:

- ▶ El accuracy calculado para el dataset del sistema va a tender al accuracy de la población
- ▶ Si se ejecutaba el sistema intervenido con los datos del modelo su accuracy hubiera tendido a la media de la población

Explicación

Como ambas accuracies tienden a lo mismo, los cálculos van a ser correctos:

$$\blacktriangleright \overline{m_{FN}^{S_{* \rightarrow p}, D}} \xrightarrow{p} m_{FN}^{S_{* \rightarrow p}, D}$$

$$\blacktriangleright \overline{m_{TP}^{S_{* \rightarrow p}, D}} \xrightarrow{p} m_{TP}^{S_{* \rightarrow p}, D}$$

$$\blacktriangleright \overline{m_{TP}^{S_{* \rightarrow n}, D}} \xrightarrow{p} m_{TP}^{S_{* \rightarrow n}, D}$$

Preguntas?